

问题一 模型的建立

1.1 问题分析与建模思路

问题一要求刻画男胎 Y 染色体浓度与检测孕周、孕妇 BMI 及其他指标之间的相关特性，并建立可进行显著性检验的关系模型。附件中的同一孕妇可能对应多次采血或同次采血的重复检测，若直接把全部记录视为相互独立，会低估参数估计的不确定性。此外，Y 染色体浓度与各连续指标的分布形态未必满足正态假设，预先固定使用 Pearson 相关系数也可能造成检验方法与数据特征不匹配。

既往基于母体血浆游离 DNA 的研究发现，胎儿 DNA 比例通常随孕周增加而上升，并随孕妇体重或 BMI 增加而下降 [1-3]。这些研究为本题变量选择提供了外部依据，但其研究指标主要是胎儿 DNA 比例，并不与附件中的男胎 Y 染色体浓度完全等同，因此本文仍以附件数据完成关系估计和显著性检验。

据此，本文建立“分布检验—自适应相关分析—候选关系模型—聚类稳健推断—分组交叉验证”的分析框架。首先对 Y 染色体浓度、孕周、BMI、年龄、身高、体重及测序质量指标进行正态性检验；随后根据每一对变量的分布判定结果，在 Pearson 与 Spearman 相关分析之间自适应选择，并用错误发现率校正控制多重比较带来的偶然显著。关系模型以孕周和 BMI 为主要解释变量，以年龄为控制变量，同时设置线性模型与含二次项、交互项的扩展模型。参数估计时按孕妇代码计算聚类稳健标准误，模型比较时也以孕妇为分组单位进行交叉验证，从而使统计推断和泛化能力评价与数据的重复测量结构保持一致。

1.2 符号说明

设共有 M 名男胎孕妇，第 i 名孕妇有 n_i 条有效检测记录， j 表示其第 j 条记录。本文主要符号如表 1 所示。

表 1 主要符号及含义

符号	含义
y_{ij}	第 i 名孕妇第 j 次记录的 Y 染色体浓度，单位为百分比
w_{ij}	该记录对应的十进制孕周
b_{ij}	该记录对应的孕妇 BMI
a_i	孕妇年龄
h_i	孕妇身高与体重
q_i	原始读段数、比对比例、重复读段比例、GC 含量和过滤读段比例等测序质量指标的统称
$\bar{y}_{ij}$	对应变量经均值中心化后的取值

符号	含义
	关系模型的待估参数向量
	未被解释的随机扰动项
	显著性水平，取0.05

1.3 数据整理与变量构造

问题一只使用附件中的男胎检测数据。将“周数+天数”形式的检测孕周统一换算为十进制周数。若原始记录为 w 周加 d 天，则

$$G_{ij} = w + \frac{d}{7}, \quad d \in \{0, 1, \dots, 6\}.$$

Y 染色体浓度、比对比例、重复读段比例、GC 含量和过滤读段比例均换算为百分数，原始读段数换算为百万条，以便统一量纲并提高结果的可读性。核心模型需要同时具备孕妇代码、Y 染色体浓度、孕周、BMI 和年龄；核心变量缺失的记录不对目标变量作插补，而是在相应分析中剔除。对只参与相关性筛查的辅助指标，采用成对完整观测进行计算，避免某一辅助变量的缺失牵连其他变量的可用记录。

身高、体重与 BMI 之间存在明确的构造关系，若三者同时进入核心回归模型，容易引入结构性共线性。因此，身高、体重及测序质量指标用于扩展相关筛查，以辨识 Y 染色体浓度可能受到的个体与检测因素影响；关系模型则聚焦题目指定的孕周和 BMI，并纳入年龄进行调整。为降低一次项与二次项、交互项之间的非必要相关性，对回归变量作均值中心化：

$$\tilde{G}_{ij} = G_{ij} - \bar{G}, \quad \tilde{B}_{ij} = B_{ij} - \bar{B}, \quad \tilde{A}_{ij} = A_{ij} - \bar{A}.$$

中心化不改变变量之间的实质关系，但可使截距具有“各连续变量处于样本平均水平时的平均 Y 染色体浓度”这一解释，并改善含高阶项模型的数值稳定性。

1.4 分布检验与自适应相关分析

1.4.1 正态性检验

对每个连续变量采用 Shapiro-Wilk 检验判断其分布是否偏离正态分布 [4]。将某变量的升序样本记为 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ ，其统计量为

$$W = \frac{\left(\sum_{k=1}^n a_k X_{(k)} \right)^2}{\sum_{k=1}^n (X_k - \bar{X})^2},$$

其中， a_k 由标准正态次序统计量的期望及协方差确定。检验假设为

$H_0: X$ 服从正态分布, $H_1: X$ 不服从正态分布.

当检验的 p 值不小于 α 时, 认为现有样本不足以拒绝正态性; 否则拒绝正态性假设。为避免仅凭单一统计量判断分布, 分析中同时计算偏度、超额峰度, 绘制直方图、核密度曲线和正态 Q-Q 图作为辅助诊断。

1.4.2 Pearson 与 Spearman 的自适应选择

设待分析的一对变量为 X 和 Z 。若二者均未拒绝正态性, 则采用 Pearson 相关系数衡量线性相关程度:

$$r_{XZ} = \frac{\sum_{k=1}^n (X_k - \bar{X})(Z_k - \bar{Z})}{\sqrt{\sum_{k=1}^n (X_k - \bar{X})^2} \sqrt{\sum_{k=1}^n (Z_k - \bar{Z})^2}}.$$

只要其中一个变量拒绝正态性, 就采用 Spearman 秩相关系数。记 $R(X_k)$ 和 $R(Z_k)$ 为观测值的秩, 则

$$\rho_{XZ} = \text{Corr}(R(X), R(Z)).$$

这种秩变换形式可自然处理孕周等变量中可能出现的并列取值, 并对偏态分布和极端值更稳健。由此定义自适应相关系数

$$C_{XZ} = \begin{cases} r_{XZ}, & X, Z \text{ 均未拒绝正态性,} \\ \rho_{XZ}, & \text{其他情形.} \end{cases}$$

对每一对变量检验

$$H_0: C_{XZ} = 0, \text{quad} H_1: C_{XZ} \neq 0.$$

同时考察多个辅助指标时, 逐项使用 0.05 作为判断标准会累积第一类错误。为此, 将全部两两相关检验的原始 p 值按从小到大排列为 $p_{(1)} \leq p_{(2)} \leq \cdots \leq p_{(m)}$, 使用 Benjamini-Hochberg 方法控制错误发现率 [5]。令

$$k^* = \max \left\{ k : p_{(k)} \leq \frac{k}{m} \alpha \right\},$$

则将前 k^* 个假设判为显著。相关分析以校正后的 p 值作为探索性筛查依据, 并通过带显著性标记的相关系数热力图呈现变量之间的整体关系。由于两两相关检验本身没有显式建模同一孕妇的重复记录, 涉及孕周、BMI 和年龄的正式显著性判断仍以第 1.6 节的聚类稳健回归为准。

1.5 Y 染色体浓度关系模型

1.5.1 线性基准模型

为直接描述孕周、BMI 与 Y 染色体浓度的平均变化关系，先建立线性基准模型：

$$Y_{ij} = \beta_0 + \beta_1 \tilde{G}_{ij} + \beta_2 \tilde{B}_{ij} + \beta_3 \tilde{A}_{ij} + \varepsilon_{ij}.$$

其中， β_1 和 β_2 分别表示在其他变量保持不变时，孕周和 BMI 每增加一个单位所对应的 Y 染色体浓度平均变化； β_3 用于控制不同年龄孕妇之间的系统差异。该模型结构简洁，可作为判断主效应方向和比较高阶模型增益的基准。

1.5.2 二次交互模型

孕周的生理变化过程未必保持恒定斜率，BMI 对 Y 染色体浓度的影响也可能随孕周而变化。为允许曲率及二者的联合作用，在基准模型上加入孕周二次项、BMI 二次项和孕周与 BMI 的交互项：

$$Y_{ij} = \beta_0 + \beta_1 \tilde{G}_{ij} + \beta_2 \tilde{B}_{ij} + \beta_3 \tilde{A}_{ij} + \beta_4 \tilde{G}_{ij}^2 + \beta_5 \tilde{B}_{ij}^2 + \beta_6 \tilde{G}_{ij} \tilde{B}_{ij} + \varepsilon_{ij}.$$

β_4 与 β_5 刻画效应随变量水平变化的弯曲程度， β_6 则表示孕周效应是否随 BMI 水平而改变。保留一次主效应后再引入二次项和交互项，使模型满足层级原则，也便于对高阶结构进行联合检验。

1.6 参数估计与显著性检验

对给定候选模型，记设计矩阵为 $\mathbf{X}$ ，响应向量为 $\mathbf{Y}$ ，首先采用普通最小二乘法估计参数：

$$\hat{\beta} = \arg \min_{\beta} (\mathbf{Y} - \mathbf{X}\beta)^T (\mathbf{Y} - \mathbf{X}\beta) = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}.$$

同一孕妇的多条记录可能共享未观测的个体特征，组内误差因而允许相关，而不同孕妇之间视为相互独立。为使标准误估计与这种组内相关结构相容，本文采用聚类稳健协方差思想 [6]。设第 i 名孕妇对应的设计矩阵和残差向量分别为 $\mathbf{X}_i$ 与 $\hat{\varepsilon}_i$ ，则按孕妇聚类的稳健协方差矩阵写为

$$\widehat{\text{Var}}(\hat{\beta}) = c (\mathbf{X}^T \mathbf{X})^{-1} \left(\sum_{i=1}^M \mathbf{X}_i^T \hat{\varepsilon}_i \hat{\varepsilon}_i^T \mathbf{X}_i \right) (\mathbf{X}^T \mathbf{X})^{-1},$$

其中 c 为有限样本修正因子。该处理不要求同一孕妇内部的误差完全独立或方差恒定，更适合附件中的重复测量结构。

单个参数采用双侧 Wald 型检验

$$H_0 : \beta_k = 0, \text{quad} H_1 : \beta_k \neq 0,$$

将参数估计量除以聚类稳健标准误，得到标准化统计量

$$T_k = \frac{\hat{\beta}_k}{\text{SE}_{\text{cluster}}(\hat{\beta}_k)}.$$

同时给出聚类稳健置信区间。整体模型使用稳健 F 检验判断全部斜率参数是否联合为零。对二次交互模型，进一步检验高阶结构是否有必要：

$H_0 : \beta_4 = \beta_5 = \beta_6 = 0, quad H_1 : \text{至少一个高阶项系数不为 } 0.$

令约束矩阵为 $\mathbf{R}$ ，使 $\mathbf{R}\boldsymbol{\beta} = (\beta_4, \beta_5, \beta_6)^\top$ ，Wald 统计量为

$$W = \left(\mathbf{R}\widehat{\boldsymbol{\beta}}\right)^\top \left[\mathbf{R}\widehat{\text{Var}}\left(\widehat{\boldsymbol{\beta}}\right)\mathbf{R}^\top\right]^{-1} \left(\mathbf{R}\widehat{\boldsymbol{\beta}}\right).$$

该检验用于判断曲率和交互作用作为一个整体是否提供额外信息，而不依赖对单个高阶系数的孤立判断。

1.7 共线性与残差诊断

对每个非截距解释变量计算方差膨胀因子。设用其他解释变量回归第 k 个解释变量所得决定系数为 R_k^2 ，则

$$\text{VIF}_k = \frac{1}{1 - R_k^2}.$$

VIF 用于识别一次项、二次项和交互项之间是否存在过强的线性依赖。模型残差另行接受 Jarque–Bera 正态性检验、Breusch–Pagan 异方差检验 [11] 和 Durbin–Watson 序列相关诊断。上述检验主要用于揭示模型假设可能受到的偏离；参数显著性仍以按孕妇聚类的稳健协方差为准。这里的稳健标准误用于修正推断不确定性，并不等同于消除异方差或遗漏变量。

1.8 分组交叉验证与模型确定规则

为比较线性模型和二次交互模型的样本外表现，采用按孕妇代码分组的五折交叉验证。交叉验证用于评估模型对未参与拟合样本的预测表现 [7]；对于具有重复测量或层级结构的数据，划分方式还应与其依赖结构相匹配 [8]。因此，本文先对孕妇代码随机打乱并分成五组，每一折将其中一组孕妇的全部记录作为验证集，其余孕妇的记录作为训练集。同一孕妇的记录不会同时进入训练集和验证集，因而不会把同一个体的信息泄漏到验证环节。随机划分使用固定种子 2025，以保证计算过程可复现。

设第 s 折验证集含 N_s 条记录，实际值和预测值分别为 Y_l 与 $\widehat{Y}_l$ ，计算

$$\text{RMSE}_s = \sqrt{\frac{1}{N_s} \sum_{l=1}^{N_s} \left(Y_l - \widehat{Y}_l\right)^2},$$

$$\text{MAE}_s = \frac{1}{N_s} \sum_{l=1}^{N_s} \left|Y_l - \widehat{Y}_l\right|,$$

$$R_s^2 = 1 - \frac{\sum_{l=1}^{N_s} \left(Y_l - \widehat{Y}_l\right)^2}{\sum_{l=1}^{N_s} \left(Y_l - \bar{Y}_s\right)^2}.$$

以五折平均 RMSE 作为主要选择标准，平均 MAE 和平均 R^2 用于辅助判断。最终关系形式由该预先规定的规则确定，再在完整数据上估计其参数并实施聚类稳健显著性检验。这样的处理将“统计关系是否存在”和“模型能否对新孕妇保持稳定预测”分开评价，避免仅凭样本内拟合优度选择复杂模型。

1.9 调整效应曲线的构造

为展示孕周和 BMI 可能存在的非线性及交互变化，效应曲线统一由二次交互候选模型构造；最终关系模型的确定仍遵循第 1.8 节的交叉验证规则。考察孕周时，将 BMI 和年龄固定在各自样本均值，仅令孕周在其样本主要分布区间内连续变化；考察 BMI 时采取相同方式，将孕周和年龄固定在均值。若给定变量组合对应的设计向量为 $\mathbf{x}_0$ ，则模型预测及其标准误为

$$\widehat{Y}_0 = \mathbf{x}_0^T \widehat{\boldsymbol{\beta}},$$
$$\text{SE}(\widehat{Y}_0) = \sqrt{\mathbf{x}_0^T \widehat{\text{Var}}(\widehat{\boldsymbol{\beta}}) \mathbf{x}_0}.$$

据此绘制预测曲线及 95% 置信带，并叠加原始散点与 LOWESS 局部加权趋势作为描述性参照。图中同时标出题目给定的 Y 染色体浓度 4% 达标线，但该阈值只作为临床判别背景，不参与问题一关系模型的参数估计。效应曲线反映的是在控制其他变量后的统计关联，不作因果解释，也不用于观测范围之外的外推。

1.10 模型假设与适用边界

模型建立基于以下假设：不同孕妇之间相互独立，同一孕妇内部允许存在任意形式的残差相关；在附件覆盖的孕周和 BMI 范围内，Y 染色体浓度的条件均值可由所设线性或二次交互结构近似；核心变量的观测误差不会系统性地随未观测健康状态改变；聚类稳健推断能够在不严格规定组内协方差结构的情况下给出合理的不确定性估计。

本文模型用于描述附件样本中的统计相关关系。年龄、身高、体重和测序质量指标的筛查有助于识别潜在影响因素，但不能替代随机试验或完整的生理机制分析；对未纳入模型的妊娠方式、个体基础状况等因素，仍可能存在残余混杂。因此，模型结论应限定在数据覆盖的人群与取值区间内，并与后续问题中的时点决策模型区分使用。

问题一 模型的求解

2.1 样本概况与分布检验结果

按模型建立部分的数据口径整理男胎检测记录后，共得到 1082 条可用于核心模型的记录，涉及 267 名孕妇。孕妇代码、Y 染色体浓度、检测孕周、BMI 和年龄均无缺失，因而核心模型未对目标变量或解释变量进行插补。数据中有 40 组“同一孕妇同次抽血对应多次检测”的情形，单组最多包含 3 次检测，这也是后续按孕妇代码计算聚类稳健标准误、并按孕妇划分交叉验证折次的依据。

表 1 给出了三个核心变量的描述统计与 Shapiro-Wilk 检验结果。Y 染色体浓度的均值为 7.7187%，检测孕周均值为 16.8457 周，BMI 均值为 32.2888。三个变量的检验 p 值均远小于 0.05，年龄、身高、体重以及各测序质量指标也得到相同的非正态判定。因此，本题的两两相关分析实际均采用 Spearman 秩相关系数。

表 1 核心变量的分布特征与正态性检验

变量	均值	标准差	中位数	取值范围	Shapiro-Wilk W	p 值	判定
Y 染色体浓度 (%)	7.7187	3.3518	7.5066	1.0004~23.4218	0.9676		非正态
孕周 (周)	16.8457	4.0763	16.0000	11~29	0.9198		非正态
孕妇 BMI	32.2888	2.9724	31.8116	20.7031~46.8750	0.9429		非正态




图 1 中，Y 染色体浓度和 BMI 均呈右偏，孕周的柱形分布则受检测时点集中和周数离散化影响，表现出明显的多峰起伏。三幅分布图中的 Shapiro-Wilk 检验均拒绝正态性，与表 1 的数值判断一致。




图 2 进一步显示，三个变量的样本分位数均未沿正态参考线稳定分布。Y 染色体浓度和 BMI 在右尾处偏离较明显，孕周的 Q-Q 图呈阶梯状，这说明采用对分布假设要求较低的秩相关分析更为合适。

2.2 Y 染色体浓度的相关特性

对全部两两相关检验进行 Benjamini-Hochberg 错误发现率校正后，Y 染色体浓度与 10 个候选指标的相关结果见表 2。除 GC 含量外，其余 9 个指标在 0.05 水平下均达到显著，但相关系数绝对值均未超过 0.2，属于极弱相关。由此可见，样本量使较弱的统计关系也能够被识别，显著性不能直接等同于强解释力。


表 2 Y 染色体浓度与各指标的 Spearman 相关结果

指标	Spearman ρ	FDR 校正 p 值	方向	显著性						
体重 (kg)	-0.1670	4.54×10^{-7}	负相关	***		比对比例 (%)	-0.1594	1.48×10^{-6}	负相关	***
孕妇 BMI	-0.1550	2.37×10^{-6}	负相关	***		年龄 (岁)	-0.1172	6.13×10^{-4}	负相关	***
重复读段比例 (%)	0.1058	0.0022	正相关	**		身高 (cm)	-0.1011	0.0037	负相关	**
过滤读段比例 (%)	0.0860	0.0170	正相关	*		原始读段数 (百万)	-0.0860	0.0170	负相关	*
孕周 (周)	0.0843	0.0190	正相关	*		GC 含量 (%)	-0.0166	0.7653	负相关	不显著

注：显著性标记依据 FDR 校正后的 p 值，*、**、*** 分别表示 $p < 0.05$ 、 $p < 0.01$ 、 $p < 0.001$ 。

其中，孕周与 Y 染色体浓度呈弱正相关，BMI 与 Y 染色体浓度呈弱负相关，方向与题目给出的经验认识一致。年龄、体重和比对比例也呈显著负相关，但这些结果仍属于未控制其他因素时的边际关系。BMI 与体重的相关系数达到 0.7711，身高与体重的相关系数为 0.6490，若把 BMI、身高和体重同时放入核心模型，会造成重复表达体型信息，因此回归阶段保留 BMI，并将年龄作为控制变量。

自适应相关系数与显著性热力图
(两变量均正态用皮尔逊法, 否则用斯皮尔曼法)



注：显著性标记基于本杰明尼-霍赫贝格错误发现率校正，* p<0.05，** p<0.01，*** p<0.001。

图 3 汇总了主要变量之间的相关方向和 FDR 校正后的显著性。热力图中 Y 染色体浓度与孕周的单元格为浅红色，与 BMI、年龄、身高、体重和比对比例的单元格为浅蓝色，说明这些关系的方向稳定但强度有限；BMI、体重和身高之间较深的暖色块则反映了体型指标之间较强的结构相关。

2.3 候选模型比较与模型确定

线性模型和二次交互模型均采用按孕妇代码分组的五折交叉验证。根据模型建立部分预先规定的规则，以平均 RMSE 较小者作为最终关系模型。表 3 显示，二次交互模型的平均 RMSE 和平均 MAE 均略低于线性模型，平均 R^2 略高，因此选取二次交互模型。

表 3 候选模型的分组五折交叉验证结果

模型	平均 RMSE（百分点）	RMSE 标准差	平均 MAE（百分点）	MAE 标准差	平均 R^2	R^2 标准差
二次交互模型	3.2607	0.3395	2.6347	0.2024	0.0413	0.0215

模型	平均 RMSE（百分点）	RMSE 标准差	平均 MAE（百分点）	MAE 标准差	平均 R^2	R^2 标准差
线性模型	3.2626	0.3410	2.6504	0.2188	0.0402	0.0247

两种模型的平均 RMSE 仅相差约 0.0019 个百分点，说明二次项和交互项带来的预测增益较小。样本内比较也呈现类似特征：二次交互模型的 AIC [9] 为 5622.6876，低于线性模型的 5628.2741；但其 BIC [10] 为 5657.5936，高于线性模型的 5648.2203，表明在施加更强复杂度惩罚时，线性模型仍具有简洁性优势。本文不据此夸大复杂模型的提升，而是遵循事先确定的交叉验证规则完成选择。

二次项与交互项的联合 Wald 统计量为 9.5979，自由度为 3， $p = 0.0223$ ，在 0.05 水平下拒绝“孕周二次项、BMI 二次项和孕周-BMI 交互项系数同时为零”的原假设。该结果说明高阶结构整体上包含额外信息，为保留二次交互模型提供了显著性依据。

2.4 参数估计及关系模型

在完整样本上重新估计二次交互模型，并按孕妇代码计算聚类稳健标准误，所得参数见表 4。孕周一次项、BMI 一次项、年龄一次项和孕周二次项均在 0.05 水平下显著；BMI 二次项及孕周-BMI 交互项的单项检验未达到显著。高阶项的联合检验显著而部分单项不显著，说明非线性信息主要由孕周曲率贡献，同时各高阶项应结合整体模型理解。

表 4 二次交互模型的参数估计与聚类稳健检验

参数	估计值	聚类稳健标准误	统计量	p 值	95% 置信区间	判定
截距	7.6419	0.2323	32.894		[7.1865, 8.0972]	显著
孕周中心化	0.0975	0.0307	3.173	0.0015	[0.0373, 0.1577]	显著
BMI 中心化	-0.1659	0.0659	-2.517	0.0119	[-0.2951, -0.0367]	显著
年龄中心化	-0.1059	0.0507	-2.088	0.0368	[-0.2053, -0.0065]	显著
孕周二次项	0.0117	0.0053	2.188	0.0287	[0.0012, 0.0222]	显著
BMI 二次项	-0.0153	0.0114	-1.340	0.1802	[-0.0377, 0.0071]	不显著
孕周-BMI 交互项	0.0100	0.0103	0.968	0.3329	[-0.0102, 0.0301]	不显著

记 G 、 B 、 A 分别为孕周、BMI 和年龄，则最终关系模型为

$$\begin{aligned}\widehat{Y} = & 7.641878 + 0.097468(G - 16.8457) - 0.165873(B - 32.2888) - 0.105887(A - 28.9399) \\ & + 0.011689(G - 16.8457)^2 - 0.015328(B - 32.2888)^2 \\ & + 0.009957(G - 16.8457)(B - 32.2888).\end{aligned}$$

在孕周、BMI 和年龄均处于样本平均水平时，模型给出的 Y 染色体浓度均值为 7.6419%。在其他变量处于中心水平附近时，孕周每增加 1 周，Y 染色体浓度平均增加约 0.0975 个百分点；BMI 每增加 1 个单位，平均降低约 0.1659 个百分点；年龄每增加 1 岁，平均降低约 0.1059 个百分点。由于模型含有二次项和交互项，这些数值是中心点附近的局部效应，不能视为整个取值区间内恒定不变的斜率。

孕周与胎儿 Y 染色体浓度的相关显著性及效应曲线




图 4 中，原始记录离散程度较大，LOWESS 曲线在若干检测密集区间出现局部起伏；控制 BMI 和年龄后的模型效应曲线整体随孕周缓慢上升。Spearman 系数为 0.0843、FDR 校正 $p = 0.0190$ ，与回归模型中孕周一次项和二次项的正向估计相互印证。效应曲线在主要样本区间内高于 4% 达标线，但它描述的是条件均值，不能据此断言每名孕妇在相同孕周均能达到阈值。

孕妇 BMI 与胎儿 Y 染色体浓度的相关显著性及效应曲线




图 5 显示，控制孕周和年龄后，模型调整效应随 BMI 增大而下降。该方向与 Spearman 系数 -0.1550 及其 FDR 校正 $p = 2.37 \times 10^{-6}$ 一致。高 BMI 区域的样本较少，置信带随之变宽；因此，曲线末端的下降幅度应作区间内的趋势解释，不宜外推到附件未充分覆盖的人群。

2.5 模型诊断与解释边界

二次交互模型的整体聚类稳健检验为 $F = 7.7032$ ， $p = 1.20 \times 10^{-7}$ ，说明孕周、BMI、年龄及高阶项作为一个整体与 Y 染色体浓度显著相关。各解释变量的 VIF 均较低，最大值为 1.4672，未发现需要重点关注的多重共线性。

表 5 汇总了最终模型的拟合与残差诊断结果。样本内 R^2 为 0.0698，调整 R^2 为 0.0646，表明模型只能解释 Y 染色体浓度变异中的一小部分。样本内 RMSE 为 3.2313 个百分点，按孕妇分组交叉验证的平均 RMSE 为 3.2607 个百分点，两者较为接近，没有表现出明显的样本内过拟合，但绝对误差仍不可忽略。

表 5 二次交互模型的拟合与诊断指标

指标	数值	说明
样本内 R^2	0.0698	模型解释度有限
调整 R^2	0.0646	计入模型复杂度后的解释度
样本内 RMSE（百分点）	3.2313	样本内绝对误差
样本内 MAE（百分点）	2.6076	样本内平均绝对误差
五折平均 RMSE（百分点）	3.2607	按孕妇分组验证
五折平均 MAE（百分点）	2.6347	按孕妇分组验证
Jarque-Bera 检验 p 值		残差偏离正态分布
Breusch-Pagan 检验 p 值		存在异方差迹象
Durbin-Watson 统计量	0.8406	仅作残差序列相关参考
最大 VIF	1.4672	共线性处于可接受范围

残差正态性和同方差性均未得到支持，且同一孕妇可能有多条检测记录，因此使用按孕妇聚类的稳健标准误是必要的。稳健标准误只修正参数推断的不确定性，并不能提高模型对个体差异、测序波动或未观测因素的解释能力。结合较低的 R^2 与较大的记录间离散程度，本模型更适合概括群体层面的相关方向和平均变化，不宜被当作单次检测的高精度预测工具。

2.6 问题一结论

综合分布检验、相关分析和聚类稳健回归，男胎 Y 染色体浓度与检测孕周呈显著但较弱的正相关，与孕妇 BMI 呈显著但较弱的负相关；年龄、体重、比对比例等指标也表现出一定的边际关联。按孕妇分

组五折交叉验证后，二次交互模型以略低的平均 RMSE 被选为关系模型，高阶项联合检验也支持保留非线性结构。

最终模型在整体上具有统计显著性，并给出了孕周、BMI 和年龄经相互调整后的变化方向。不过，其解释度和交叉验证增益均有限，说明胎儿 Y 染色体浓度还受到较强的个体差异、检测误差及其他未纳入因素影响。因此，本题所得关系应理解为附件样本范围内的观察性统计关联，而非因果效应；其主要作用是后续按 BMI 分组和选择 NIPT 时点提供定量依据。

参考文献

- [1] Wang E, Batey A, Struble C, Musci T, Song K, Oliphant A. Gestational age and maternal weight effects on fetal cell-free DNA in maternal plasma. *Prenatal Diagnosis*, 2013, 33(7): 662–666. <https://doi.org/10.1002/pd.4119>
- [2] Ashoor G, Syngelaki A, Poon L C Y, Rezende J C, Nicolaides K H. Fetal fraction in maternal plasma cell-free DNA at 11–13 weeks' gestation: relation to maternal and fetal characteristics. *Ultrasound in Obstetrics & Gynecology*, 2013, 41(1): 26–32. <https://doi.org/10.1002/uog.12331>
- [3] Hou Y, Yang J, Qi Y, et al. Factors affecting cell-free DNA fetal fraction: statistical analysis of 13,661 maternal plasmas for non-invasive prenatal screening. *Human Genomics*, 2019, 13: 62. <https://doi.org/10.1186/s40246-019-0244-0>
- [4] Shapiro S S, Wilk M B. An analysis of variance test for normality (complete samples). *Biometrika*, 1965, 52(3/4): 591–611. <https://doi.org/10.1093/biomet/52.3-4.591>
- [5] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 1995, 57(1): 289–300. <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>
- [6] Liang K Y, Zeger S L. Longitudinal data analysis using generalized linear models. *Biometrika*, 1986, 73(1): 13–22. <https://doi.org/10.1093/biomet/73.1.13>
- [7] Stone M. Cross-validatory choice and assessment of statistical predictions. *Journal of the Royal Statistical Society: Series B*, 1974, 36(2): 111–133. <https://doi.org/10.1111/j.2517-6161.1974.tb00994.x>
- [8] Roberts D R, Bahn V, Ciuti S, et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 2017, 40(8): 913–929. <https://doi.org/10.1111/ecog.02881>
- [9] Akaike H. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 1974, 19(6): 716–723. <https://doi.org/10.1109/TAC.1974.1100705>
- [10] Schwarz G. Estimating the dimension of a model. *The Annals of Statistics*, 1978, 6(2): 461–464. <https://doi.org/10.1214/aos/1176344136>

[11] Breusch T S, Pagan A R. A simple test for heteroscedasticity and random coefficient variation. *Econometrica*, 1979, 47(5): 1287–1294. <https://doi.org/10.2307/1911963>